Sistema de segmentación automática de vértebras en radiografías mediante aprendizaje profundo.

Camilo Albarracín, Andres Castellano, Sebastián Morelli Moreno,
Nicolás Sánchez Saavedra, Joshua Sancho Burgos
Ingeniería de Sistemas y Computación
Universidad de los Andes, Bogotá, Colombia
c.albarracinb@uniandes.edu.co, aa.castellano@uniandes.edu.co,
sm.morelli@uniandes.edu.co, jn.sanchezs1@uniandes.edu.co, j.sancho@uniandes.edu.co

***Resumen*—La segmentación automática de vértebras en radiografías anteroposteriores es un problema abierto con aplicación directa en el diagnóstico y seguimiento de la escoliosis. Este trabajo presenta el diseño, entrenamiento y evaluación comparativa de cuatro enfoques de aprendizaje profundo sobre el *MaIA Scoliosis Dataset*: segmentación por instancias con Mask R-CNN, un pipeline híbrido de detección YOLO y segmentación local con *TinyUNet*, segmentación de instancias en una sola etapa con YOLOv26-seg, y una arquitectura U-Net multi-cabeza con función de pérdida enriquecida con restricciones anatómicas. Los tres primeros enfoques evidenciaron limitaciones estructurales amplificadas por errores sistemáticos de anotación presentes en el 47.6 % del dataset. El cuarto enfoque mitigó este problema incorporando conocimiento anatómico explícito (orden céfalo-caudal y suavidad del eje espinal) directamente en la función de pérdida, produciendo segmentaciones fisiológicamente más coherentes evaluadas por inspección visual y métricas estructurales. El modelo ocupa 7.47 MB y opera en CPU en 0.683 s por imagen, evidenciando su viabilidad en entornos clínicos con recursos computacionales limitados.**

***Index Terms*—segmentación vertebral, aprendizaje profundo, radiografías, escoliosis, detección de objetos**

I. Introducción

La escoliosis es una deformidad estructural de la columna vertebral caracterizada por una curvatura lateral anormal en forma de "S" o "C", cuya importancia clínica trasciende la alteración estética: en casos severos, con ángulos de Cobb superiores a los 40 grados, puede derivar en dolor crónico, fatiga muscular limitante y compromiso de la capacidad pulmonar por compresión de órganos internos [1]. Aunque la variante idiopática adolescente es la más prevalente, la patología afecta a individuos de todas las edades con orígenes congénitos, neuromusculares o degenerativos.

El estándar clínico para su diagnóstico y seguimiento es la radiografía anteroposterior (AP) de columna completa y la medición manual del ángulo de Cobb. Este procedimiento, sin embargo, presenta limitaciones críticas: la identificación manual de las vértebras límite es altamente dependiente del operador, con variabilidades inter-observador reportadas de entre 4° y 8°, margen suficiente para alterar una decisión terapéutica entre tratamiento conservador y cirugía [2]. A esto se suma la carga operativa sobre el personal especializado en entornos de alta demanda, y las restricciones de las herramientas comerciales existentes (como *BoneMetrics* o *Surgimap*), que son propietarias, costosas y frecuentemente requieren intervención manual ante deformidades severas o imágenes de baja calidad [3].

Desde el punto de vista técnico, el problema presenta desafíos específicos que la literatura aún no ha resuelto completamente. La gran mayoría de los avances en segmentación vertebral automática se han desarrollado sobre imágenes de Tomografía Computarizada (CT) en 3D, impulsados por benchmarks como VerSe [4]. Trasladar estos logros a la radiografía 2D no es trivial: la naturaleza proyectiva de la imagen genera superposición de costillas, órganos abdominales y gas intestinal que oscurece los bordes vertebrales, especialmente en la región lumbar y la unión toracolumbar [5]. Adicionalmente, las arquitecturas de mayor rendimiento (como los modelos fundacionales basados en Vision Transformers o el *Segment Anything Model* (SAM)) requieren hardware de aceleración (GPUs de alta gama) que resulta inviable en consultorios periféricos, hospitales rurales o equipos portátiles de países en vías de desarrollo [6].

Este trabajo propone y evalúa un sistema de segmentación automática de vértebras torácicas (T1–T12) y lumbares (L1–L5) en radiografías AP, comparando cuatro enfoques de aprendizaje profundo: (1) segmentación por instancias con Mask R-CNN; (2) un pipeline híbrido de detección con YOLO y segmentación local con *TinyUNet*; (3) segmentación de instancias en una sola etapa con YOLOv11-seg; y (4) una arquitectura U-Net con tres cabezas de predicción especializadas y un pipeline geométrico para la estimación del ángulo de Cobb. La evaluación se realiza sobre el *MaIA Scoliosis Dataset* [7], 206 radiografías con anotaciones de segmentación por vértebra y metadatos clínicos.

Una auditoría sistemática del *Ground Truth* reveló que cerca del 48 % de las imágenes presentan anomalías en sus anotaciones (máscaras sobredimensionadas, etiquetas fragmentadas, huecos anatómicos e inversiones de orden cráneo-caudal). Estos hallazgos motivaron el cuarto enfoque, que incorpora la coherencia anatómica global directamente en la función de pérdida mediante una U-Net con tres cabezas complementarias: coordenada axial (z), primer plano (*fg logits*) y refinamiento (*refine logits*). Sobre la segmentación resultante opera un pipeline geométrico que estima el ángulo de Cobb mediante *spline* cúbico e identificación de los puntos de

curvatura máxima opuesta.

Las contribuciones principales son: (i) evaluación comparativa y crítica de cuatro paradigmas de segmentación con auditoría cuantitativa del *Ground Truth*; (ii) diseño de *TinyUNet*, arquitectura ligera para segmentación vertebral local; (iii) análisis de las causas estructurales del bajo rendimiento de los enfoques basados en detección de instancias; y (iv) arquitectura U-Net multi-cabeza con pérdida anatómica y pipeline geométrico interpretable para la estimación clínica del ángulo de Cobb.

II. Estado del Arte

La revisión de la literatura en segmentación vertebral automática para el diagnóstico de escoliosis revela cuatro ejes temáticos que fundamentan tanto la necesidad como la viabilidad técnica del presente trabajo.

II-A. Segmentación vertebral: del CT en 3D a los rayos X en 2D

El campo de la segmentación vertebral ha estado históricamente dominado por el análisis de imágenes volumétricas (CT y MRI), impulsado por grandes bases de datos abiertas como VerSe [4], que provee anotaciones de segmentación para más de 300 pacientes en tomografía multi-detector. En este dominio, arquitecturas encoder-decoder como U-Net [8] y variantes de Mask R-CNN [9] han alcanzado una madurez notable, con coeficientes Dice superiores a 0.90 en regiones torácicas. Sin embargo, la literatura reciente evidencia la dificultad de trasladar estos modelos a la radiografía 2D. Konya et al. [5] demostraron que los modelos semánticos fallan al distinguir vértebras adyacentes visualmente fusionadas por efecto de la proyección, señalando que la segmentación por instancias —que trata cada vértebra como un objeto independiente— es el enfoque correcto para el análisis de escoliosis en rayos X. Más recientemente, Lu et al. [10] propusieron un flujo de trabajo completamente automatizado que combina detección y etiquetado vertebral, logrando resultados robustos en imágenes clínicas de diversa calidad.

El reto específico de la radiografía reside en su naturaleza proyectiva: la superposición de costillas, gas intestinal y tejido blando sobre los cuerpos vertebrales degrada el contraste local de los bordes óseos, especialmente en la unión toracolumbar (T12–L1) y en la región lumbar baja (L4–L5). En respuesta a este problema, Gu et al. [11] presentaron MDWC-Net, una red de contexto multi-escala con ponderación dinámica diseñada específicamente para manejar los bordes difusos y el bajo rango dinámico de las imágenes de rayos X espinales, alcanzando resultados superiores a enfoques estándar en este tipo de imágenes.

II-B. Arquitecturas de segmentación: CNNs, Transformers y modelos de espacio de estados

Para abordar la limitación de las redes convolucionales (CNNs) en la captura de contexto global (aspecto crítico para modelar la curvatura en "S" de la escoliosis a lo largo de toda la columna) surgieron las arquitecturas basadas en *Vision Transformers* (ViT). Modelos como Swin-UNet [12], UNETR [13] y SegFormer [14] han demostrado superar a las CNNs puras en tareas de segmentación médica con estructuras de gran extensión espacial, al modelar dependencias de largo alcance mediante mecanismos de atención. En 2024, los modelos basados en espacio de estados como U-Mamba [15] prometen capturar estas dependencias con complejidad computacional lineal, representando la frontera actual del modelado biomédico eficiente.

En el contexto de la detección de objetos aplicada a la segmentación vertebral, la familia YOLO (*You Only Look Once*) ocupa un lugar relevante por su equilibrio entre velocidad y precisión. YOLOv11 [16] incorpora un diseño *anchor-free* y un *backbone* CSPNet que facilita inferencias rápidas incluso en CPU, optimizando una función de pérdida compuesta que penaliza simultáneamente el error en cajas delimitadoras, la clasificación y la segmentación a nivel de píxel. No obstante, Da Mutten et al. [17] señalaron que los enfoques de detección pura presentan limitaciones al capturar la continuidad anatómica de la columna, validando que la segmentación densa es más adecuada para este problema.

II-C. Modelos fundacionales y adaptación eficiente

La irrupción del *Segment Anything Model* (SAM) ha desplazado el paradigma hacia modelos de segmentación generalistas con capacidad *zero-shot*. Sin embargo, SAM en su forma estándar es computacionalmente prohibitivo para entornos clínicos locales con hardware modesto. En respuesta, trabajos de 2024 y 2025 han presentado adaptaciones médicas especializadas: Wu et al. [6] propusieron el *Medical SAM Adapter*, que ajusta los parámetros de SAM para imágenes médicas mediante módulos ligeros de adaptación; mientras que Gao et al. [18] presentaron *Swin-LiteMedSAM*, una versión destilada operativa en conjuntos de datos médicos de gran escala. Estas tendencias validan la búsqueda de arquitecturas que preserven la capacidad de generalización sin exigir infraestructura de alto costo.

II-D. Medición automática del ángulo de Cobb y diagnóstico de escoliosis

Más allá de la segmentación, la literatura reciente aborda directamente la automatización del diagnóstico de escoliosis. Meng et al. [2] demostraron que sistemas de aprendizaje profundo pueden automatizar la medición de parámetros espinales con alta concordancia con las mediciones manuales de expertos, cuantificando la variabilidad inter-observador humana entre $4°$ y $8°$, margen clínicamente relevante para la toma de decisiones terapéuticas. Por su parte, Hayashi et al. [3] validaron un algoritmo de aprendizaje profundo para la medición automatizada del ángulo de Cobb con alta precisión en radiografías clínicas, abriendo la vía para su integración en flujos de trabajo radiológicos. En el plano metodológico, Yang et al. [19] propusieron técnicas de aprendizaje contrastivo guiado por bordes (BoCLIS) para entrenar modelos robustos bajo supervisión semi-supervisada, estrategia especialmente

valiosa cuando el volumen de datos anotados es reducido, como ocurre en el presente trabajo.

En conjunto, la revisión evidencia que persiste un vacío en soluciones que integren segmentación vertebral precisa, eficiencia computacional en CPU y operabilidad clínica sobre radiografías 2D con datasets de tamaño limitado. Un factor que la literatura suele soslayar es la calidad del *Ground Truth*: incluso datasets cuidadosamente curados pueden contener errores sistemáticos de anotación que, en conjuntos pequeños, tienen un impacto desproporcionado sobre la generalización del modelo [19]. Los enfoques que privilegian la coherencia anatómica global (modelando el orden cráneo-caudal como restricción estructural) representan una respuesta directa tanto a esta fragilidad de los datos como a las limitaciones de los paradigmas de detección por instancias. El presente trabajo se posiciona en esta intersección.

III. Metodología

III-A. Conjunto de datos

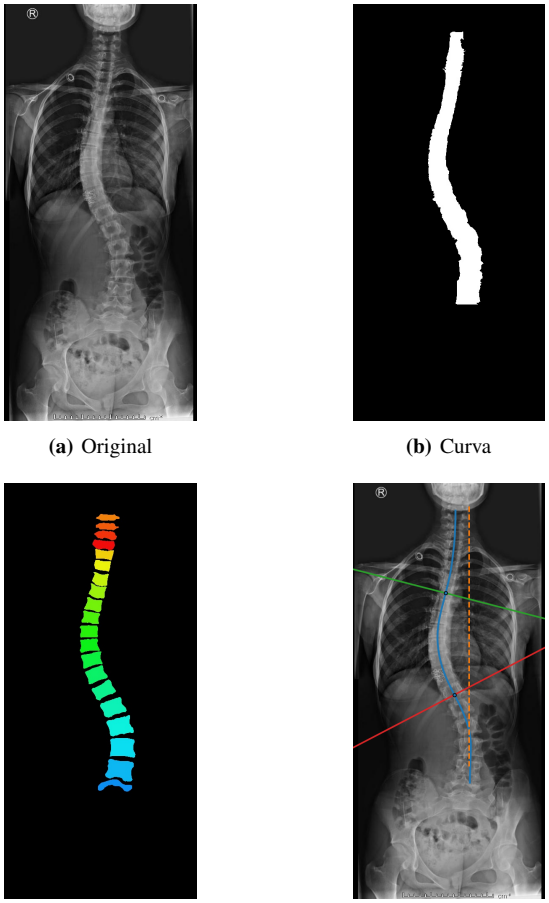
El conjunto de datos utilizado en este estudio corresponde a una versión curada del *MaIA Scoliosis Dataset* [7], proporcionada por el profesor Luis Felipe Giraldo Trujillo de la Universidad de los Andes (Bogotá, Colombia). El dataset comprende 206 radiografías anteroposteriores (AP) de columna vertebral, tanto de vista completa como seccionada, acompañadas de anotaciones de segmentación a nivel de vértebra individual.

III-A1. Estructura de las anotaciones: Cada imagen cuenta con cuatro representaciones complementarias que permiten el entrenamiento de arquitecturas de segmentación y la validación clínica de los resultados (véase la Figura 1):

- **Radiografía original:** imagen AP en escala de grises, que constituye la entrada al modelo.
- **Máscara binaria:** segmentación de dos clases (fondo = 0, columna = 255), utilizada para tareas de detección global de la región de interés.
- **Máscara multiclase (PNG):** anotación de 18 clases con identificadores enteros consecutivos: clase 0 para el fondo, clases 1–12 para las vértebras torácicas T1–T12 y clases 13–17 para las vértebras lumbares L1–L5. Esta es la referencia principal para el entrenamiento y la evaluación del modelo.
- **Overlay de métricas:** imagen compuesta que integra los trazados de las curvas de Cobb, la Línea Sacra Vertical Central (CSVL) y otras referencias anatómicas, empleada para la validación clínica cualitativa.

Complementariamente, se dispone de metadatos numéricos para cada imagen, incluyendo el ángulo de Cobb medido manualmente (en grados) y las coordenadas de la Línea Sacra Vertical Central (CSVL), definidas en píxeles.

III-A2. Distribución y características estadísticas: El dataset presenta un desbalance moderado: 71 imágenes de columna normal (34.46 %) y 135 de escoliosis (65.54 %), según la Tabla I. Las imágenes de escoliosis muestran mayor media de brillo (109.19 vs. 100.64) y mayor desviación estándar (69.07 vs. 47.32), atribuible a deformidades óseas e instrumentación quirúrgica, lo que representa un desafío adicional para el



(a) Original **(b)** Curva

(c) Segmentación multiclase **(d)** Overlay de métricas

Figura 1: Componentes visuales del *MaIA Scoliosis Dataset*. (a) Radiografía AP original; (b) máscara binaria de curvatura; (c) máscara multiclase con codificación de color por vértebra (T1–T12 en gradiente amarillo-verde, L1–L5 en gradiente cian-azul); (d) overlay con curvas de Cobb y referencias anatómicas. Fuente: [7].

aprendizaje. La partición se realizó mediante estratificación en dos etapas con `train_test_split` (semilla `SEED=42`), resultando en una división aproximada 80/10/10 que preserva la proporción Normal/Escoliosis en cada subconjunto.

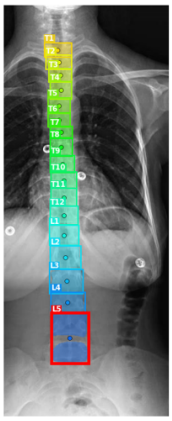
Cuadro I: Distribución del *MaIA Scoliosis Dataset* por condición clínica.

Categoría	Imágenes	Porcentaje
Columna Normal	71	34.46 %
Escoliosis	135	65.54 %
Total	**206**	**100 %**

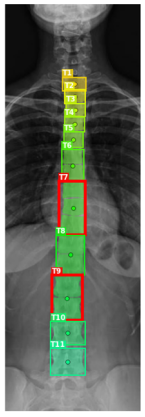
Estos hallazgos explican en parte el bajo rendimiento de los tres primeros enfoques evaluados y constituyeron el argumento central para el diseño del cuarto enfoque, que incorpora la validez anatómica directamente en la función de pérdida en lugar de depender exclusivamente de la coherencia del *Ground Truth*.

III-A3. Auditoría de calidad del Ground Truth: Se realizó una validación automática sobre las 250 imágenes del dataset

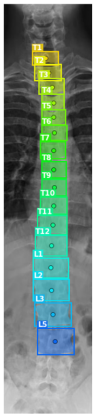
aplicando cuatro reglas de verificación estructural (véase la Tabla III-A3). Los resultados muestran que 119 imágenes (47.6 %) presentan al menos una alerta: 112 con máscaras sobredimensionadas que engloban más de una vértebra; 9 con huecos en la secuencia anatómica; 3 con etiquetas fragmentadas; y 1 con inversión del orden cráneo-caudal. Doce imágenes acumulan más de dos tipos de alerta simultáneos, constituyendo los casos de mayor riesgo para el entrenamiento (véase la Figura 2).



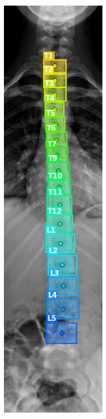
(a) Etiqueta L5 discontinua, cubre dos vértebras



(b) Múltiples etiquetas T con más de una vértebra incluida



(c) Hueco anatómico: L4 ausente entre L3 y L5



(d) Hueco anatómico: T8 ausente en la secuencia torácica

Figura 2: Ejemplos representativos de los errores de anotación detectados en el *MaIA Scoliosis Dataset*. (a) Etiqueta L5 fragmentada que cubre dos vértebras; (b) máscaras torácicas sobredimensionadas; (c) secuencia lumbar con L4 sin etiquetar; (d) secuencia torácica con T8 sin etiquetar. Elaboración propia.

Regla	**Procedimiento**
`large mask outlier`	Para cada vértebra anotada se compara su área y la altura/ancho de su *bounding box* contra la distribución global del dataset. Las anotaciones se reescalan isotrópicamente a 1024×512 px. Se marca cuando la mediana estandarizada supera un z robusto de 3.
`internal sequence gap`	Se verifica que las etiquetas presentes formen una secuencia continua entre la primera y la última vértebra visible. Una secuencia T1, T3 sin T2, o L3, L5 sin L4, se marca como hueco.
`disconnected same label`	Para cada clase del *Ground Truth* se buscan componentes conexas. Si una misma vértebra aparece en dos regiones significativas separadas, se marca como etiqueta fragmentada o duplicada.
`centroid order inversion`	Se verifica el orden cráneo-caudal: los centroides deben descender siguiendo T1 $\rightarrow$ T12 $\rightarrow$ L5. Se marca si una vértebra superior aparece más abajo que la siguiente.

III-B. Preprocesamiento y aumento de datos

El pipeline de procesamiento se implementó con *Albumentations* [20] en tres etapas. El **preprocesamiento determinístico** aplica sincronizadamente sobre imagen y máscara: recorte aleatorio de extremos (hasta 25 % por lado, p=0.20) para simular radiografías parciales; reescalado proporcional a 1024 px en la dimensión mayor; *padding* + recorte centrado a 1024×512 px; y ecualización adaptativa de histograma CLAHE (clip=2) para mejorar el contraste de bordes óseos.

El **aumento de datos** es diferenciado por clase. Para columna normal (esquema agresivo): volteo horizontal, transformación afín ($\pm 12°$, traslación 5 %, escala 0.9–1.1$\times$), deformación elástica ($\alpha = 30$, $\sigma = 5$, p=0.30), ruido gaussiano y desenfoque. Para escoliosis (esquema conservador): volteo horizontal y rotación acotada ($\pm 10°$) con ajustes leves de intensidad, preservando la curvatura patológica. Finalmente, cada imagen se **normaliza** con $\mu = 0{,}3974$ y $\sigma = 0{,}0802$ y se convierte a tensor de PyTorch con tres componentes: imagen flotante, máscara multiclase (18 clases) y etiqueta binaria diagnóstica (véase la Figura 3).

III-C. Enfoque 1: Segmentación por instancias con Mask R-CNN

El primer enfoque trata cada una de las 17 vértebras (T1–T12 y L1–L5) como una instancia independiente mediante Mask R-CNN, combinando un *backbone* ResNet-50 con pirámide de rasgos (FPN), una *Region Proposal Network*

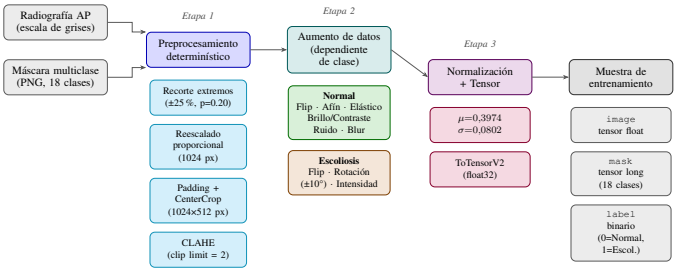


Figura 3: Pipeline de procesamiento de datos. Las tres etapas se aplican secuencialmente a cada par imagen/máscara. El aumento de datos (Etapa 2) varía según la clase clínica para preservar la morfología patológica de la escoliosis.

(RPN) y cabezas de predicción independientes para clasificación, regresión de caja y segmentación por instancia. La arquitectura de referencia (**modelo Avance**) usa `maskrcnn_resnet50_fpn_v2` con pesos COCO completos, capas superiores entrenables (`layer2–layer4`) y normalización con estadísticas propias del dataset ($\mu = 0{,}3974$, $\sigma = 0{,}0802$). La evaluación reveló que esta normalización desalineaba la distribución de entrada respecto al preentrenamiento en ImageNet, colapsando la curva de validación. Se diseñaron tres variantes correctivas: **Modelo A** adopta estadísticas ImageNet estándar ($\mu = [0{,}485, 0{,}456, 0{,}406]$) manteniendo el resto de la configuración; **Modelo B** sustituye el *backbone* por pesos RadImageNet (dominio médico), inicializando FPN, RPN y cabezas desde cero; **Modelo C** combina pesos COCO completos con *backbone* RadImageNet para aprovechar ambas fuentes. Como paso adicional, sobre el Modelo A se evaluó un postprocesamiento Viterbi que busca la secuencia T1→L5 óptima penalizando inconsistencias de posición, área y etiqueta.

En todos los modelos se usó SGD con momento 0.9 y tasas diferenciadas: 5×10^{-4} para el *backbone* y 5×10^{-3} para las cabezas. Se reportan métricas de detección (mAP@50, mAP@95) y segmentación semántica (Dice macro, IoU macro) sobre 50 imágenes de validación estratificadas.

III-D. Enfoque 2: Pipeline híbrido (Detección + Segmentación local)

El segundo enfoque descompone el problema en dos etapas: detección global de vértebras con `yolo26n` (variante ligera con pesos preentrenados, resolución 1024×512 px), seguida de segmentación binaria local condicionada a cada detección. A partir de las cajas predichas se extraen parches con un margen de 24 px de contexto circundante, normalizados a 256×256 px, transformando el problema multiclase en múltiples subproblemas binarios independientes.

La segmentación local la realiza *TinyUNet*, una U-Net compacta de tres niveles encoder-decoder con bloques Conv-BN-ReLU y conexiones *skip* simétricas, optimizada con una pérdida combinada de entropía cruzada binaria (BCE) y coeficiente Dice. Las máscaras resultantes se reproyectan a la imagen completa asignando a cada región la etiqueta YOLO correspondiente (en solapamientos prevalece la detección de mayor puntuación). YOLO se entrenó con el pipeline de la Sección III-B; *TinyUNet* se entrenó de forma independiente con Adam ($\text{lr} = 1 \times 10^{-3}$). Se reportan métricas de detección (mAP@50, mAP@50-95) y segmentación *foreground* (Dice, IoU) sobre imagen completa.

III-E. Enfoque 3: Segmentación de instancias con YOLO-seg

El tercer enfoque integra detección y segmentación en una única red mediante YOLOv11-seg [16], cuya función de pérdida compuesta penaliza simultáneamente el error en cajas ($\mathcal{L}_{\text{CIoU}}$), la clasificación ($\mathcal{L}_{\text{BCE}}$) y la segmentación a nivel de píxel ($\mathcal{L}_{\text{mask}}$). El enfoque se desarrolló en tres aproximaciones sucesivas. La **aproximación 1** (yolo11n-seg, 30 épocas, lr=1×10^{-3}) confirmó viabilidad básica de localización (mAP@50 = 0.223). La **aproximación 2** escaló al modelo *small* (yolo11s-seg, 100 épocas) pero reveló que la pérdida semántica (`sem_loss`) permanecía en cero durante todo el entrenamiento, indicando que la cabeza de segmentación no recibía gradientes útiles, causado por la conversión defectuosa de máscaras al formato poligonal requerido por YOLO y la ejecución exclusiva en CPU sin precisión mixta. La **aproximación 3** corrigió el proceso de exportación de etiquetas y habilitó entrenamiento en GPU, lo que estabilizó los gradientes de la cabeza de segmentación y permitió el cierre experimental del enfoque.

III-F. Enfoque 4: Segmentación Guiada por Conocimiento Anatómico

Los tres enfoques anteriores evidenciaron una limitación estructural común: al optimizarse exclusivamente sobre las anotaciones del *ground truth*, los modelos absorbían el ruido sistemático del dataset (47.6 % de imágenes con irregularidades), produciendo segmentaciones fragmentadas y sin coherencia céfalo-caudal. El Enfoque 4 incorpora conocimiento anatómico explícito en la función de pérdida para aprender restricciones fisiológicas independientemente de la calidad de las etiquetas.

III-F1. Arquitectura: El modelo sigue una estructura *encoder-decoder* U-Net [21] (`in_channels=1`, `out_channels=18`, `base_channels=16`, 7.47 MB) con tres cabezas de predicción diferenciadas:

- **Cabeza de coordenada axial** (`z`): mapa escalar continuo $z \in [0, 1]$ que asigna a cada píxel su posición relativa a lo largo del eje céfalo-caudal, dotando al modelo de noción explícita de orden anatómico global.
- **Cabeza de primer plano** (`fg_logits`): segmentación binaria columna/fondo que suprime contribuciones de costillas, tejidos blandos y artefactos adyacentes.
- **Cabeza de refinamiento** (`refine_logits`): logits multiclase de 18 canales para afinar contornos y forma vertebral local.

III-F2. Mecanismo de Inferencia: Las tres cabezas se combinan mediante un pipeline geométrico diferenciable. A partir de `z` se computan probabilidades blandas de

pertenencia a cada vértebra mediante una función de asignación gaussiana:

$$p_v(x,y) = \frac{\exp\left(-\dfrac{(z(x,y)-c_v)^2}{\sigma}\right)}{\displaystyle\sum_{v'=1}^{17} \exp\left(-\dfrac{(z(x,y)-c_{v'})^2}{\sigma}\right)} \tag{1}$$

donde $c_v = \texttt{linspace}(0{,}05,\ 0{,}95,\ 17)$ son anclas anatómicas uniformes y $\sigma = 0{,}03$. La señal de primer plano $f_g = \sigma(\texttt{fg_logits})$ actúa como compuerta multiplicativa ($\tilde{p}_v = p_v \cdot f_g$) suprimiendo el fondo. Los logits de refinamiento se fusionan mediante suma en espacio logarítmico:

$$\ell_v^{\text{final}}(x,y) = \texttt{refine_logits}_v(x,y) + \log(\tilde{p}_v(x,y) + \varepsilon) \tag{2}$$

imponiendo las probabilidades anatómicas como un *prior* sobre los logits de refinamiento. La predicción final se obtiene por *argmax* sobre ℓ^{final}.

III-F3. Función de Pérdida con Restricciones Anatómicas: La función de pérdida total integra tres términos:

$$\mathcal{L} = \mathcal{L}_{\text{seg}} + 0{,}5\,\mathcal{L}_{\text{fg}} + 0{,}3\,\mathcal{L}_{\text{anat}} \tag{3}$$

donde $\mathcal{L}_{\text{seg}}$ es la entropía cruzada multiclase sobre los logits fusionados, $\mathcal{L}_{\text{fg}}$ es la entropía cruzada binaria de la cabeza de primer plano, y $\mathcal{L}_{\text{anat}}$ constituye el aporte central:

$$\mathcal{L}_{\text{anat}} = \mathcal{L}_{\text{mono}} + 0{,}5\,\mathcal{L}_{\text{smooth}} \tag{4}$$

La **pérdida de monotonicidad** $\mathcal{L}_{\text{mono}}$ penaliza inversiones en el campo z a lo largo del eje vertical:

$$\mathcal{L}_{\text{mono}} = \frac{1}{N}\sum_{x}\sum_{y} \text{ReLU}(z(x,y) - z(x,y+1)) \tag{5}$$

La **pérdida de suavidad** $\mathcal{L}_{\text{smooth}}$ penaliza variaciones abruptas en z en ambas direcciones:

$$\mathcal{L}_{\text{smooth}} = \frac{1}{N}\sum_{x,y} \left(|z(x,y) - z(x{+}1,y)| + |z(x,y) - z(x,y{+}1)|\right) \tag{6}$$

Ambas restricciones son agnósticas respecto al *ground truth*: regulan directamente la geometría del campo z hacia soluciones fisiológicamente plausibles, incluso cuando las anotaciones son inconsistentes.

III-F4. Pipeline para el Ángulo de Cobb: El ángulo de Cobb se estima en cuatro etapas desacopladas de la inferencia: (1) cálculo de centroides por clase vertebral segmentada; (2) ajuste de un *spline* cúbico sobre los centroides para reconstruir el eje continuo de la columna; (3) identificación de los puntos de pendiente máxima y mínima opuesta mediante análisis de la derivada del *spline*; y (4) medición del ángulo entre las perpendiculares a la tangente en esos dos puntos extremos, que aproximan los platillos vertebrales de la curva escoliótica principal. El ángulo resultante se presenta numéricamente en el *front-end* sin renderizarse sobre la imagen radiográfica.

III-F5. Configuración de Entrenamiento: Optimizador Adam con $\text{lr} = 10^{-4}$ y precisión mixta (`torch.cuda.amp.GradScaler`); lote de 2 (entrenamiento) y 8 (validación); partición 80/10/10 estratificada por diagnóstico con `SEED=42`; normalización con $\mu = 0{,}3974$, $\sigma = 0{,}0802$.

III-G. Despliegue de la Aplicación

El modelo se integró en una API REST desarrollada con *FastAPI* (*SpineSeg Inference API*). La interfaz recibe una radiografía en escala de grises y retorna vía `POST /segment` un objeto JSON con cuatro campos: imagen anotada con segmentación, *spline* espinal y líneas de Cobb (`annotated_img`); máscara de segmentación por identificador de vértebra (`mask_img`); ángulo de Cobb en grados (`cobb_angle`); y puntuaciones de confianza por vértebra (`vertebrae`), con imágenes codificadas en *base64*. El servicio se configura mediante variables de entorno (`DEVICE`, `PORT`, `WEIGHTS_PATH`) y admite ejecución en GPU (0.683 s) o CPU (60 s). La documentación interactiva queda disponible en `/docs` mediante el esquema OpenAPI de *FastAPI*.

El *frontend* presenta resultados en tres paneles (véase la Figura 4): imagen original, segmentación anotada con *spline* y líneas de Cobb, y panel de resultados con ángulo estimado, su clasificación clínica (normal, leve, moderado o severo) y estadísticas de confianza por nivel vertebral.

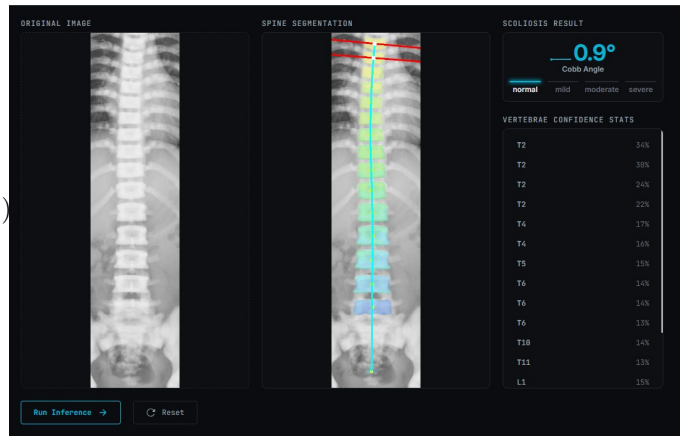


Figura 4: Interfaz de la aplicación *SpineSeg*. El panel izquierdo muestra la imagen original; el central, la superposición de la segmentación con el eje espinal y las líneas del ángulo de Cobb; el derecho, el ángulo estimado con su clasificación clínica y las puntuaciones de confianza por vértebra.

IV. Resultados

IV-A. Resultados — Enfoque 1: Mask R-CNN

La Tabla II resume las métricas finales de los cuatro modelos evaluados sobre el conjunto de validación ($n = 50$). El Modelo A, con normalización ImageNet, es el único que logra resultados cuantitativamente significativos y sirve como referencia para el resto del análisis.

Cuadro II: Métricas finales del Enfoque 1 sobre el conjunto de validación ($n = 50$). Dice e IoU calculados en modo macro sobre 17 clases vertebrales.

Modelo	mAP@50	mAP@95	Dice	IoU
Avance (norm. dataset)	0.065	0.024	0.006	0.005
A – COCO + ImageNet	0.354	0.288	0.172	0.152
B – RadImageNet body	0.218	0.121	0.071	0.058
C – COCO + RadImageNet	0.261	0.196	0.086	0.073
A + Viterbi (post-proc.)	0.528	0.411	0.305	0.269

IV-A1. Análisis cuantitativo: El modelo de referencia del avance obtuvo mAP@50 de 0.065 y Dice macro de 0.006, evidenciando fallo casi completo por la desalineación entre la distribución de entrada y la que el *backbone* preentrenado en ImageNet espera. El Modelo A, que corrige únicamente la normalización, multiplica el mAP@50 por un factor de 5.4 (a 0.354) y el Dice de 0.006 a 0.172, confirmando que la normalización era el cuello de botella estructural. El Modelo B (RadImageNet) queda por debajo (mAP@50 = 0.218, Dice = 0.071): la pérdida de los pesos COCO en FPN, RPN y cabezas supera la ganancia de dominio en el *backbone*. El Modelo C ocupa una posición intermedia (mAP@50 = 0.261, Dice = 0.086). El postprocesamiento Viterbi sobre el Modelo A eleva el Dice macro de 0.172 a 0.305, confirmando que la señal de continuidad anatómica T1→L5 aporta información que el modelo no captura de forma intrínseca, lo que expone la limitación fundamental del paradigma: la mejora proviene de una heurística externa, no de que el modelo haya aprendido la estructura global de la columna.

IV-A2. Análisis cualitativo: La Figura 5 compara los cuatro modelos sobre una imagen normal (`N2.jpg`) y una con escoliosis (`S103.jpg`). El Modelo A logra coberturas razonables en la región torácica alta, pero con etiquetas inconsistentes en la región lumbar. En presencia de escoliosis, la curvatura lateral acentúa los errores de localización de la RPN, produciendo cajas desplazadas y solapamientos. El postprocesamiento Viterbi recupera coherencia secuencial, pero no corrige formas anatómicamente incorrectas.

IV-B. Resultados — Enfoque 2: Pipeline híbrido

La Tabla III resume las métricas finales del pipeline híbrido completo, comparando el modelo del informe de avance con los resultados obtenidos tras el entrenamiento extendido de *TinyUNet*. Las métricas se reportan de forma diferenciada por etapa: detección para YOLO y segmentación *foreground* para el pipeline completo.

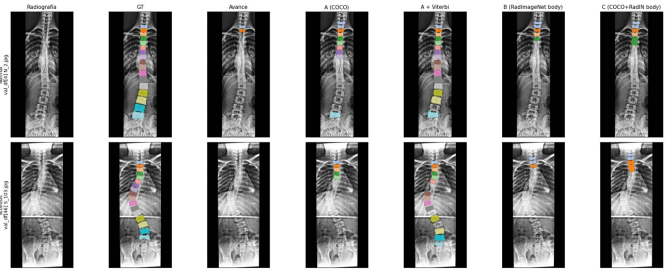


Figura 5: Comparación cualitativa de los cuatro modelos del Enfoque 1 y el postprocesamiento Viterbi sobre una imagen Normal (`N_2.jpg`, fila superior) y una con escoliosis (`S_103.jpg`, fila inferior). Columnas de izquierda a derecha: Radiografía, *Ground Truth*, Avance, A (COCO+ImageNet), A+Viterbi, B (RadImageNet), C (COCO+RadImageNet). Elaboración propia.

Cuadro III: Métricas finales del Enfoque 2. Detección evaluada sobre la etapa YOLO; segmentación evaluada sobre el pipeline completo reconstruido en imagen completa (*foreground*).

Configuración	mAP@50	mAP@95	Dice	IoU
Avance (TinyUNet)	0.119	0.014	0.147	–
Pipeline completo (final)	0.318	0.238	0.597	0.452

"–": métrica no disponible en esa configuración.

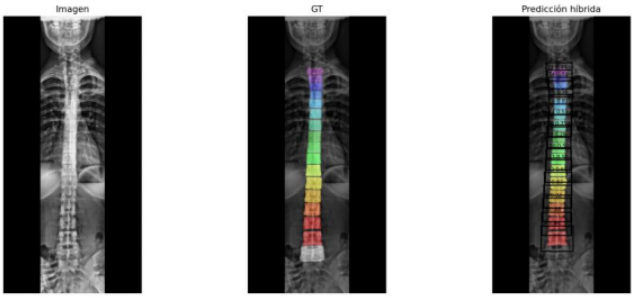
IV-B1. Análisis cuantitativo: El resultado más relevante del enfoque es la mejora sustancial de *TinyUNet* con entrenamiento extendido: el Dice de validación local en *crops* pasó de 0.747 (informe de avance, 5 épocas) a 0.917 en la versión final. Sin embargo, esta ganancia no se traduce de forma directa al pipeline completo *end-to-end*, que registra un Dice *foreground* de 0.597 e IoU de 0.452. La brecha entre ambas cifras cuantifica el impacto de la etapa de detección: cuando YOLO omite vértebras, las desplaza o asigna etiquetas incorrectas, la red de segmentación local no tiene posibilidad de recuperarlas, independientemente de su calidad individual.

La etapa de detección YOLO registró un mAP@50 de 0.318 y un mAP@50-95 de 0.238, valores que reflejan una localización razonable en casos simples pero con alta variabilidad ante deformidades pronunciadas o regiones de bajo contraste. Este comportamiento es la principal fuente de degradación del pipeline global.

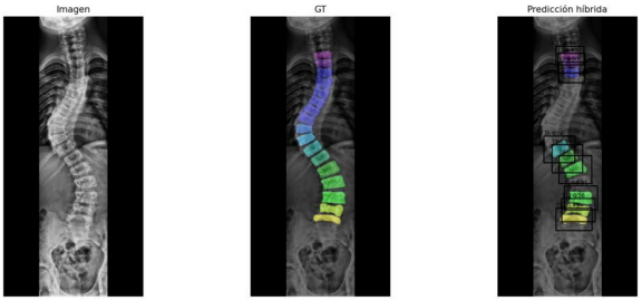
IV-B2. Análisis cualitativo: La Figura 6 ilustra los dos escenarios extremos del pipeline. En la imagen normal (`N_4.jpg`), la detección YOLO ofrece buena cobertura de la columna y *TinyUNet* reconstruye una segmentación coherente con contornos bien definidos a lo largo de toda la estructura vertebral. En la imagen con escoliosis (`S_69.jpg`, Dice = 0.676, IoU = 0.511), la curvatura lateral introduce errores en las cajas delimitadoras de YOLO, con omisiones y desplazamientos en la región lumbar que la etapa de segmentación no puede compensar, produciendo una reconstrucción fragmentada en la mitad inferior de la columna.

Este contraste confirma la dependencia estructural del pipeline: el techo de rendimiento de *TinyUNet* está

condicionado por la cobertura del detector. En casos de columna normal con buena alineación vertical, el enfoque es viable y produce resultados cualitativamente aceptables; ante deformidades severas, la propagación de errores entre etapas limita severamente la calidad de la segmentación final.



(a) Normal



(b) Escoliosis

Figura 6: Resultados cualitativos del Enfoque 2 (pipeline híbrido). Columnas: Imagen original, *Ground Truth*, Predicción híbrida. Fila superior: columna normal (N_4), con buena cobertura de detección y segmentación coherente. Fila inferior: escoliosis (`S_69`, Dice = 0.676), con omisiones en la región lumbar debidas a errores de detección. Elaboración propia.

En conjunto, los resultados confirman la viabilidad conceptual del pipeline híbrido pero evidencian que la propagación de errores entre etapas es una limitación estructural inherente.

IV-C. Resultados — Enfoque 3: YOLO-seg

La Tabla IV resume las métricas obtenidas en las tres aproximaciones del enfoque. Los resultados de la aproximación 3 con entrenamiento en GPU están pendientes de actualización con los valores finales.

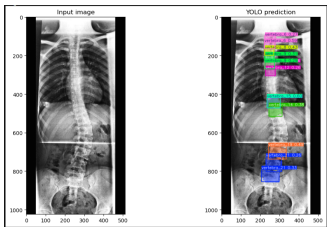
Cuadro IV: Resultados comparativos del Enfoque 3 por aproximación. Métricas evaluadas sobre el conjunto de validación.

Aproximación	mAP@50	mAP@95	Dice	IoU
Línea base	0.223	0.096	–	–
YOLO26s-seg Escalado	0.467	0.201	0.439	0.384
Corrección estructural + GPU	0.511	0.22	0.455	0.409

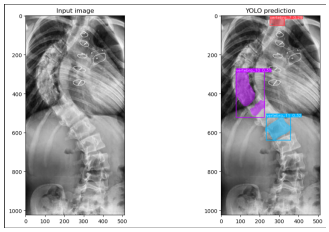
"–": métrica no disponible en esa configuración.

IV-C1. Análisis cuantitativo: La aproximación 1 (yolo11n-seg, mAP@50 = 0.223) confirmó viabilidad básica de localización. La aproximación 2 mejoró la detección (mAP@50 = 0.467) pero la pérdida semántica permaneció en cero durante todo el entrenamiento, confirmando que la conversión defectuosa al formato poligonal impedía que la cabeza de segmentación recibiera gradientes útiles. La aproximación 3, con corrección de etiquetas y entrenamiento en GPU, representa el cierre experimental (mAP@50 = 0.511, Dice = 0.455, IoU = 0.409). Incluso con estas correcciones, el diseño por instancias independientes impide modelar la continuidad T1→L5 y la compresión geométrica poligonal introduce pérdida de información que se amplifica durante el aprendizaje sobre anotaciones ruidosas.

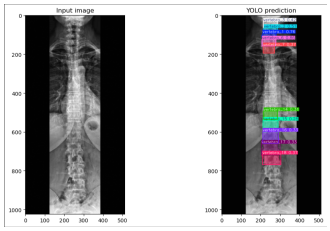
IV-C2. Análisis cualitativo: La Figura 7 muestra resultados representativos del enfoque. El modelo logra identificar múltiples vértebras distribuidas a lo largo de la columna con localización espacial razonable en casos de baja curvatura (subfiguras a y c), pero la precisión de las máscaras es limitada y la consistencia entre niveles vertebrales adyacentes es baja. En presencia de escoliosis (subfigura b), la irregularidad estructural acentúa los errores de localización y fragmenta las predicciones de segmentación. La variante de mayor capacidad (subfigura d) incrementa la densidad de detecciones pero introduce redundancias y solapamientos que no se traducen en una mejora proporcional en la calidad de las máscaras.



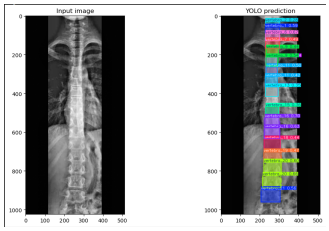
(a) Detección de vértebras



(b) Segmentación (escoliosis)



(c) Segmentación (normal)



(d) Modelo extendido

Figura 7: Resultados representativos del Enfoque 3 (YOLO-seg). (a) Detección de vértebras en columna normal. (b) Segmentación en imagen con escoliosis. (c) Segmentación en columna normal. (d) Variante de mayor capacidad con mayor densidad de detecciones. Elaboración propia.

IV-D. Resultados — Enfoque 4

IV-D1. Consideraciones sobre la Evaluación Cuantitativa: El Enfoque 4 fue diseñado para divergir de anotaciones erróneas en favor de predicciones fisiológicamente plausibles. Como consecuencia, las métricas Dice e IoU calculadas contra el *ground truth* pueden penalizar predicciones anatómicamente correctas que no coincidan con

anotaciones defectuosas. Una reducción en dichas métricas no implica degradación clínica, sino la distancia entre la predicción y unas etiquetas imprecisas en casi la mitad de los casos. Por esta razón, la evaluación del Enfoque 4 se apoya principalmente en métricas estructurales y análisis cualitativo por inspección visual.

IV-D2. Métricas Estructurales: Junto a las métricas de superposición píxel a píxel, el modelo fue evaluado con tres indicadores de coherencia anatómica derivados de los centroides vertebrales predichos:

- **Violaciones de orden** (*Ordering Violations*): número de pares consecutivos de vértebras cuyo centroide vertical predito viola el orden céfalo-caudal esperado. Un modelo con coherencia anatómica perfecta obtendría un valor de 0.
- **Cobertura** (*Coverage*): proporción de clases vertebrales presentes en el *ground truth* que también son detectadas en la predicción. Valores próximos a 1.0 indican que el modelo no omite vértebras.
- **Fragmentación** (*Fragmentation Score*): número total de componentes conexas adicionales por clase más allá del segmento principal. Refleja la cohesión espacial de cada vértebra predicha.

Cuadro V: Métricas estructurales del Enfoque 4 sobre el conjunto de validación. Las métricas de superposición se reportan como referencia, reconociendo las limitaciones del *ground truth* descritas en el texto.

Métrica	Valor
IoU (referencia)	0.126
Dice (referencia)	0.167
Violaciones de orden	2.35
Cobertura vertebral	0.98
Fragmentación	1142.78

IV-D3. Análisis Cualitativo: La Figura 8 muestra el campo z superpuesto sobre una radiografía de validación: el gradiente azul-amarillo recorre de forma continua y suave la columna de cérvico-torácico a lumbar, confirmando que el modelo codificó el orden anatómico global. La ausencia de discontinuidades contrasta marcadamente con las segmentaciones fragmentadas de los enfoques anteriores. La Figura 9 muestra la curva de verificación de orden: la predicción (naranja) sigue la tendencia monótona descendente del *ground truth* (azul) con desviaciones acotadas, confirmando que $\mathcal{L}_{\text{anat}}$ regula efectivamente el orden de las predicciones. La Figura 10 ilustra el pipeline de estimación del ángulo de Cobb en tres casos de validación, produciendo estimaciones coherentes incluso en escoliosis pronunciada.

IV-D4. Costo Computacional: El modelo ocupa 7.47 MB en disco, opera en CPU con tiempo de inferencia de 0.683 s por imagen, consumo de RAM de 1 489 MB e incremento de CPU del 43.80 % (Tabla VI), lo que demuestra viabilidad en entornos clínicos con recursos limitados.

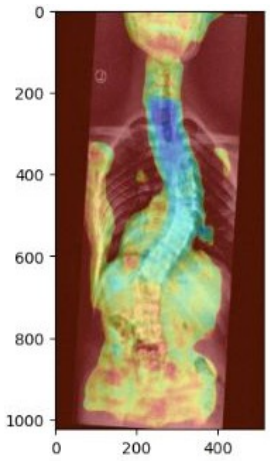


Figura 8: Campo de coordenada axial z (mapa de calor *jet*) superpuesto sobre la radiografía de entrada. El gradiente céfalo-caudal continuo evidencia que el modelo codificó el orden anatómico global a lo largo de toda la columna.

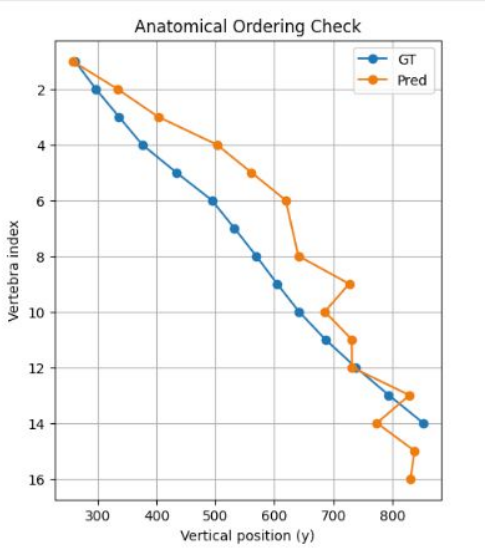


Figura 9: Verificación de orden anatómico para una muestra de validación. El eje y representa el índice vertebral (1–17) y el eje x la posición vertical media del centroide. La predicción (naranja) mantiene la monotonía céfalo-caudal en concordancia con el *ground truth* (azul).

V. Discusión y Aportes

V-A. Comparación entre enfoques

Los cuatro enfoques representan una progresión conceptual motivada por las limitaciones de cada etapa anterior. Mask R-CNN (Enfoque 1) alcanza un mAP@50 de 0.528 con Viterbi, pero trata cada vértebra como objeto aislado sin restricción que impida inversiones de orden. El pipeline YOLO–*TinyUNet* (Enfoque 2) demuestra alta calidad de contornos locales (Dice = 0.917 en *crops*), pero la propagación de errores del detector es estructuralmente irreversible: el techo del pipeline completo (Dice = 0.597) queda condicionado por la cobertura del detector, no por la

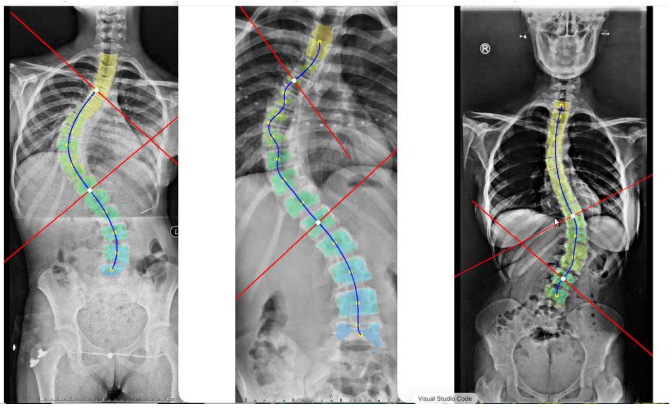


Figura 10: Estimación del ángulo de Cobb mediante el pipeline geométrico del Enfoque 4 en tres casos de validación. El *spline* azul representa el eje espinal reconstruido a partir de los centroides por banda; las líneas rojas marcan las perpendiculares a los puntos de inclinación máxima opuesta que determinan el ángulo de Cobb.

Cuadro VI: Perfil computacional del Enfoque 4 en inferencia sobre CPU.

Indicador	Valor
Tamaño del modelo en disco	7.47 MB
Tiempo de inferencia (por imagen)	0.683 s
Uso de RAM	1 489.28 MB
Incremento de CPU (delta)	43.80 %

capacidad de *TinyUNet* [17]. YOLOv11-seg (Enfoque 3) afronta el mismo problema: la reconstrucción poligonal introduce pérdida geométrica que se amplifica con anotaciones ruidosas, y sin un mecanismo que propague el orden céfalo-caudal, el modelo trata cada detección como objeto autónomo [5], [16], [17]. El Enfoque 4 reformula el problema hacia segmentación densa con conocimiento anatómico explícito en la función de pérdida.

V-B. Limitaciones de los datos y validez del Enfoque 4

El 47.6 % de las imágenes del *MaIA Scoliosis Dataset* presentan irregularidades en sus anotaciones [7]. Esta situación es frecuente en imagen médica: la variabilidad interobservador y la naturaleza proyectiva de la radiografía 2D hacen que las anotaciones manuales sean aproximaciones ruidosas de la anatomía real [2]. En conjuntos pequeños (206 imágenes), cada anotación defectuosa pesa proporcionalmente más sobre los gradientes, sin suficiente masa de ejemplos correctos que la diluya [19].

El Enfoque 4 responde directamente incorporando $\mathcal{L}_{\text{mono}}$ y $\mathcal{L}_{\text{smooth}}$ como restricciones agnósticas respecto al *ground truth*. Las métricas Dice = 0.167 e IoU = 0.126 deben interpretarse con cautela: cuando el modelo diverge intencionalmente de etiquetas erróneas, la penalización convencional constituye un artefacto de evaluación, no un indicador genuino de rendimiento [19]. La cobertura vertebral de 0.98, las 2.35 violaciones de orden promedio y la coherencia céfalo-caudal observada visualmente sustentan que las restricciones anatómicas regularon efectivamente el aprendizaje. La incorporación de conocimiento radiológico explícito (orden cráneo-caudal, suavidad del eje espinal) representa un recurso compensatorio ante la escasez y el ruido de los datos, análogo al aprendizaje semi-supervisado con supervisión estructural [19].

V-C. Viabilidad computacional y relevancia clínica

El Enfoque 4 ocupa 7.47 MB, ejecuta inferencia en 0.683 s en CPU y consume 1 489 MB de RAM, frente a modelos fundacionales (SAM, Swin-UNet, U-Mamba) que requieren GPU de alto costo [6], [15]. En el contexto latinoamericano, un sistema operable en CPU es funcionalmente más valioso que uno de mayor rendimiento métrico pero inoperable sin infraestructura especializada [2], [3]. El pipeline geométrico de Cobb produce estimaciones comparables a las reportadas en la literatura para sistemas similares [2], [3], con reproducibilidad apta para seguimiento longitudinal.

V-D. Aportes del trabajo

1. **Evaluación comparativa y crítica de cuatro paradigmas de segmentación** sobre un dataset clínico real, incluyendo una auditoría cuantitativa del *Ground Truth* que contextualiza los resultados de cada enfoque.
2. **Diseño e implementación de *TinyUNet***, arquitectura ligera U-Net para segmentación vertebral local condicionada por detección (Dice = 0.917 en *crops*).
3. **Identificación de las causas estructurales del bajo rendimiento de los enfoques basados en YOLO**: propagación de errores en cascada, incompatibilidad entre representación poligonal y segmentación densa, y conflicto de objetivos de optimización con señales ruidosas.
4. **Arquitectura U-Net multi-cabeza con pérdida anatómica y pipeline geométrico para el ángulo de Cobb**, que produce segmentaciones coherentes incluso ante *Ground Truth* ruidoso, desplegable en CPU.

V-E. Aplicaciones potenciales

El sistema tiene aplicación directa en tres escenarios: (1) apoyo al diagnóstico de escoliosis, reduciendo la carga sobre el especialista; (2) medición automatizada del ángulo de Cobb sin intervención manual, comparable en precisión a la literatura [2], [3]; y (3) seguimiento longitudinal, donde la variabilidad inter-observador humana de 4°–8° puede alterar decisiones terapéuticas [2].

VI. Conclusiones y Trabajo Futuro

Este trabajo evaluó comparativamente cuatro enfoques de aprendizaje profundo para la segmentación automática de vértebras (T1–T12, L1–L5) en radiografías anteroposteriores sobre el *MaIA Scoliosis Dataset*. Los Enfoques 1–3 evidenciaron que los paradigmas de detección por instancias independientes (Mask R-CNN, YOLO) son estructuralmente inadecuados para este problema: no modelan la continuidad T1→L5, son sensibles a los errores de anotación del *Ground Truth* (47.6 % de imágenes con irregularidades), y en pipelines en cascada la propagación de errores es irreversible.

El Enfoque 4 representa la contribución central. La incorporación de $\mathcal{L}_{\text{mono}}$ y $\mathcal{L}_{\text{smooth}}$ directamente en la función de pérdida reguló el aprendizaje hacia soluciones fisiológicamente plausibles con independencia del ruido en las etiquetas, logrando cobertura vertebral de 0.98 y coherencia céfalo-caudal cualitativamente superior. Su viabilidad computacional (7.47 MB, 0.683 s en CPU) lo hace deployable en entornos clínicos con recursos limitados, lo que es especialmente relevante para el contexto latinoamericano.

Las líneas de trabajo futuro prioritarias son:

1. **Ampliación y curación del dataset.** Con 206 imágenes y un 47.6 % de anotaciones con irregularidades, la incorporación de nuevas imágenes, revisión experta del *Ground Truth* y estrategias de aprendizaje semi-supervisado [19] son la prioridad para mejorar la generalización.
2. **Mecanismos de atención y contexto global.** Arquitecturas como Swin-UNet [12] o U-Mamba [15] podrían complementar las restricciones anatómicas con representaciones más ricas de dependencias de largo alcance a lo largo de la columna.
3. **Validación clínica del ángulo de Cobb.** La estimación geométrica del Enfoque 4 requiere validación prospectiva con mediciones manuales de especialistas para verificar si el error se sitúa dentro del margen inter-observador de 4°–8° [2], [3].
4. **Destilación y despliegue en dispositivos de borde.** Técnicas de cuantización y poda estructural sobre el modelo de 7.47 MB podrían reducir el tiempo de inferencia para integración en equipos portátiles o sistemas de telemedicina [6].

Referencias

[1] Fundación Santa Fe de Bogotá, "Escoliosis: Qué es, síntomas, tipos y tratamiento," https://fundacionsantafedebogota.com/servicios-en-salud/az-enfermedades/escoliosis, 2024, accedido: 5 de marzo de 2026.

[2] X. Meng, S. Zhu, Q. Yang, F. Zhu, X. Wang, Z. Liu, P. Dong, S. Wang, and L. Fan, "Automated measurements of spinal parameters for scoliosis using deep learning," *Spine*, vol. 50, no. 12, 2025.

[3] D. Hayashi, N.-E. Regnard, J. Ventre, V. Marty, L. Clovis, L. Lim, N. Nitche, Z. Zhang, A. Tournier, A. Ducarouge, A. J. Kompel, C. Tannoury, and A. Guermazi, "Deep learning algorithm enables automated Cobb angle measurements with high accuracy," *Skeletal Radiology*, vol. 54, pp. 1469–1478, Jul. 2025.

[4] A. Sekuboyina, M. E. Husseini, A. Bayat, M. Löffler, H. Liebl, H. Li, G. Tetteh, J. Kukačka, C. Payer, D. Štern, M. Urschler, M. Chen, D. Cheng, N. Lessmann, Y. Hu, T. Wang, D. Yang, D. Xu, F. Ambellan, T. Amiranashvili, M. Ehlke, H. Lamecker, S. Lehnert, M. Lirio, N. P. de Olaguer, H. Ramm, M. Sahu, A. Tack, S. Zachow, T. Jiang, X. Ma, C. Angerman, X. Wang, K. Brown, A. Kirszenberg, Puybareau, D. Chen, Y. Bai, B. H. Rapazzo, T. Yeah, A. Zhang, S. Xu, F. Hou, Z. He, C. Zeng, Z. Xiangshang, X. Liming, T. J. Netherton, R. P. Mumme, L. E. Court, Z. Huang, C. He, L.-W. Wang, S. H. Ling, L. D. Huỳnh, N. Boutry, R. Jakubicek, J. Chmelik, S. Mulay, M. Sivaprakasam, J. C. Paetzold, S. Shit, I. Ezhov, B. Wiestler, B. Glocker, A. Valentinitsch, M. Rempfler, B. H. Menze, and J. S. Kirschke, "VerSe: A vertebrae labelling and segmentation benchmark for multi-detector CT images," *Medical Image Analysis*, vol. 73, p. 102166, 2021.

[5] S. Kónya, T. R. S. Natarajan, H. Allouch, K. A. Nahleh, O. Y. Dogheim, and H. Boehm, "Convolutional neural network-based automated segmentation and labeling of the lumbar spine X-ray," *Journal of Craniovertebral Junction and Spine*, vol. 12, no. 2, 2021.

[6] J. Wu, Z. Wang, M. Hong, W. Ji, H. Fu, Y. Xu, M. Xu, and Y. Jin, "Medical SAM adapter: Adapting segment anything model for medical image segmentation," *Medical Image Analysis*, vol. 102, p. 103547, 2025.

[7] L. F. Giraldo Trujillo and D. F. Landínez León, "MaIA scoliosis dataset (T1–T12 y L1–L5)," 2025, dataset.

[8] M. Vania, D. Mureja, and D. Lee, "Automatic spine segmentation from CT images using convolutional neural network via redundant generation of class labels," *Journal of Computational Design and Engineering*, vol. 6, no. 2, pp. 224–232, 2019.

[9] R. Wang, J. H. Yi Voon, D. Ma, S. Dabiri, K. Popuri, and M. F. Beg, "Vertebra segmentation for clinical CT images using Mask R-CNN," in *8th European Medical and Biological Engineering Conference*, T. Jarm, A. Cvetkoska, S. Mahnič-Kalamiza, and M. Damijan, Eds. Cham: Springer International Publishing, 2021, pp. 1156–1165.

[10] H. Lu, M. Liu, K. Yu, Y. Fang, J. Zhao, and Y. Shi, "A deep learning-based fully automated vertebra segmentation and labeling workflow," *British Journal of Hospital Medicine*, vol. 86, no. 9, pp. 1–22, 2025.

[11] Z. Gu, X. Wang, and B. Chen, "MDWC-Net: A multi-scale dynamic-weighting context network for precise spinal X-ray segmentation," *Frontiers in Physiology*, vol. 16, 2025.

[12] H. Cao, Y. Wang, J. Chen, D. Jiang, X. Zhang, Q. Tian, and M. Wang, "Swin-UNet: UNet-like pure transformer for medical image segmentation," in *Computer Vision – ECCV 2022 Workshops*. Springer Nature Switzerland, 2023, pp. 205–218.

[13] A. Hatamizadeh, Y. Tang, V. Nath, D. Yang, A. Myronenko, B. Landman, H. Roth, and D. Xu, "UNETR: Transformers for 3D medical image segmentation," *arXiv preprint arXiv:2103.10504*, 2021.

[14] E. Xie, W. Wang, Z. Yu, A. Anandkumar, J. M. Alvarez, and P. Luo, "SegFormer: Simple and efficient design for semantic segmentation with transformers," *arXiv preprint arXiv:2105.15203*, 2021.

[15] J. Ma, F. Li, and B. Wang, "U-Mamba: Enhancing long-range dependency for biomedical image segmentation," *arXiv preprint arXiv:2401.04722*, 2024.

[16] R. Khanam and M. Hussain, "YOLOv11: An overview of the key architectural enhancements," *arXiv preprint arXiv:2410.17725*, 2024.

[17] R. Da Mutten, O. Zanier, S. Theiler, S.-J. Ryu, L. Regli, C. Serra, and V. E. Staartjes, "Whole spine segmentation using object detection and semantic segmentation," *Neurospine*, vol. 21, pp. 57–67, Feb. 2024.

[18] R. Gao, D. Lyu, and M. Staring, "Swin-LiteMedSAM: A lightweight box-based segment anything model for large-scale medical image datasets," *arXiv preprint arXiv:2412.13754*, 2024.

[19] Y. Yang, J. Zhuang, G. Sun, R. Wang, and J. Su, "Boundary-guided contrastive learning for semi-supervised medical image segmentation," *IEEE Transactions on Medical Imaging*, vol. 44, pp. 2973–2988, Jul. 2025.

[20] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, "Albumentations: Fast and flexible image augmentations," *Information*, vol. 11, no. 2, p. 125, 2020.

[21] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2015, pp. 234–241.