Pronóstico Semanal de Dengue en cinco municipios del Valle del Cauca

Integrantes

Andrés Felipe Flórez
Oscar Morillo
Jared Foster
Jeferson David Vargas

1. Introducción

Con este proyecto se busca anticipar el número de casos registrados de dengue con un plazo de cuatro semanas después de la última observación disponible, esto con el fin de darle tiempo a los centros de salud para prepararse ante un aumento inesperado de pacientes con esta enfermedad. Lo que se realizó fue una exploración de los datos históricos de los departamentos y se detectó que históricamente Valle del Cauca ha presentado un gran número de casos, por ende, se eligió este como caso de estudio. Aparte de esto, se realizó un estudio para determinar cuales de los municipios de este departamento son los que históricamente han tenido más casos de dengue, y los encontrados fueron Cali, Guadalajara de Buga, Palmira, Tuluá y Yumbo.

Los datos utilizados fueron los casos históricos de cada municipio combinados con sus registros semanales de precipitación y temperatura, las últimas extraídas usando Google Earth Engine. La solución propuesta permite comparar métodos sencillos de regresión, los cuales fueron tomados como los modelos referencia, con LSTM globales y locales bajo una misma separación temporal.

En este momento se utilizan series semanales con las cuales se extraen las secuencias temporales y con esto se hacen aproximadamente 160 ajustes predictivos nuevos, de los cuales 15 son los modelos referencia y 145 son redes LSTM. Se estudiaron historias de 8, 12, 16, 20 y 24 semanas, siempre para el mismo objetivo t+4, que en este caso son 4 semanas adelante.

De todas las variaciones se eligió el modelo que tuviera el menor MAE en validación, el cual fue una LSTM global de 64 unidades con una Dense intermedia de 16 neuronas y salida lineal de una neurona, sin Dropout y con 20 semanas de historia. Su MAE de validación es 11,377 casos y su RMSE es 26,837. El resultado se puede observar en la tabla a continuación:

Conjunto	Objetivos	MAE	RMSE
Entrenamiento	3,780	7,743	21,898
Validación Test	505	11,377	26,837
Test	510	38,139	95,413

Tabla 1. Desempeño del modelo elegido

2. Recolección y preparación de los datos

Los insumos epidemiológicos se encuentran en archivos anuales de 2007 a 2025 los cuales se obtuvieron del Instituto Nacional de Salud, usando los datos que se encuentran en SIVIGILA. Estos datos vienen con cifras de todos los municipios del país, por ende, se tuvo que realizar una reducción y un filtrado, de forma que solamente se dejara el código departamental 76 el cual es Valle del Cauca. En estos archivos se extrajeron las columnas:

- **COD_DPTO_O:** El cual corresponde al código del departamento
- **COD_MUN_O:** El cual corresponde al código del municipio
- **SEMANA:** El cual representa la semana epidemiológica del año
- **ANO:** El año del caso de dengue
- **INI_SIN:** Fecha de inicio de los síntomas.

Durante la lectura de los datos en el desarrollo, en el periodo de 2007 a 2023, se excluyeron 12 registros sin fecha INI_SIN y 296 sin correspondencia con el catálogo municipal usado. Los cinco municipios se eligieron por su mayor número acumulado de casos en 2007 a 2023. Cali concentra 122.040 de los 157.092 registros de ese grupo durante desarrollo.

La integración del clima, en el cual se tuvo en cuenta la temperatura promedio de la semana y la precipitación promedio de la semana en la zona, se hizo usando los datos de Google Earth Engine, de una base de datos llamada ERA5-Land la cual tiene una resolución espacial de 11 kilómetros y tiene cobertura desde 1950. Para obtener cual es la zona espacial de cada uno de los municipios se utilizaron los datos que tiene el DANE por municipio.

Estos archivos aportan específicamente precipitación y temperaturas media, máxima y mínima por municipio y semana. Unificamos ANIO como ANO y SEMANA como SEMANA_EPI, reconstruimos el código que usa el DANE de cinco dígitos y unimos por municipio, año y semana. Se conserva el calendario climático, incluidas las semanas 53 presentes en los archivos.

3. Transformaciones y construcción de secuencias

La separación temporal que se realizó para este proyecto fue usar 2007 a 2021 a los datos de entrenamiento, 2022 a 2023 a los datos de validación y 2024 a 2025 a los datos de test. Los escaladores se ajustan exclusivamente con entrenamiento y después se reutilizan para escalar en validación y test. La estandarización se hizo de la siguiente manera:

- **Casos registrados:** Se aplicó una transformación log1p y una estandarización mediante un escalador independiente por municipio. La misma transformación se utilizó para preparar la variable objetivo.

- **Tres temperaturas:** Se realizó una estandarización por variable, utilizando conjuntamente los datos de entrenamiento de todos los municipios.

- **Precipitación:** Se aplicó una transformación log1p, seguida de una estandarización compartida, ajustada con los datos de entrenamiento.

- **Semana epidemiológica:** Se utilizaron funciones de seno y coseno para representar su posición dentro del ciclo anual.

- **Municipio:** Se utilizaron cinco indicadores mediante codificación one-hot para los modelos globales.

Luego para evaluar el modelo, invertimos la estandarización con el escalador municipal y aplicamos la transformación inversa del logaritmo en el caso de la función log1p.

A continuación, se muestra un ejemplo de como se construye una secuencia utilizando una ventana de 20 periodos, que en este caso serían semanas, y el objetivo que sería los casos que van a ocurrir dentro de 4 semanas:



Ilustración 1. Ventana de entrada y semana objetivo

Cada ventana contiene siete variables temporales que pertenecen a un solo municipio. Se desplaza una semana entre las secuencias extraídas, teniendo en cuenta que únicamente se utiliza lo observado hasta t para estimar los casos de t+4.

Hay algo que sabe mencionar es que como la separación entre secuencias es de una semana, las ventanas se solapan, por lo que estos tamaños no deben interpretarse como igual número de observaciones independientes.

4. Construcción y entrenamiento de la solución

Para que la comparación sea justa entre los modelos que se han probado, se han conservado las mismas variables y las mismas fechas objetivo. Los modelos de referencia son globales, es decir, aprenden de los cinco municipios ya que se le va pasando secuencias de cada municipio aleatoriamente. Cada modelo recibe las variables de la ventana aplanada, seguida del one-hot municipal para que sepa de qué municipio es y quizá le ayude al modelo a aprender características propias. Las LSTM por otra parte, conservan la dimensión temporal, en los globales, el resumen de la red se concatena con el municipio antes de las capas Dense.

A continuación, se menciona un poco más en detalle de los modelos con los que se ha trabajado hasta este momento, tanto los modelos de referencia como los modelos objetivo que se quieren desarrollar en este proyecto.

4.1. Modelos de referencia y modelos considerados

El primer modelo que se utiliza como referencia es una regresión lineal, la cual usa la configuración predeterminada por la librería que se importó. El segundo modelo de referencia es un Random Forest, el cual utiliza 300 árboles, una profundidad máxima 12, mínimo de tres ejemplos por hoja y una semilla 42 para que en un futuro se pueda replicar. El tercer modelo que se usa como referencia es un XGBoost, el cual dispone de hasta 800 rondas, una profundidad de 3, una tasa de 0,03 y una parada temprana tras 50 rondas sin mejora en validación. Cabe destacar que para los parámetros de estos modelos referencia no se realizó una búsqueda exhaustiva de sus hiperparámetros.

Las LSTM globales tienen diversidad en la estructura, pero entre las variaciones que han aplicado en el proyecto se incluyen 32 unidades con Dense de 16 neuronas, algunas versiones no tienen la Dense intermedia, algunas usan Dropout de 0,20 y 0,50, redes de dos y tres capas, una red de 16 unidades con Dense de 8 neurona, dos capas de 32 y seis variantes de 64 unidades. Todas las variantes conservan una Dense lineal final de una neurona

Las LSTM locales, las cuales se ajustan por municipio, tienen variaciones con LSTM de 32 con una capa Dense de 16 neuronas, también se trabajó con una LSTM de 16 con una capa Dense de 8 neuronas y una LSTM de 8 con una capa Dense de 4 neuronas.

4.2. Regla de entrenamiento y de selección

Para el entrenamiento de todas las LSTM se empieza con pesos nuevos utilizando la semilla 42. Como algoritmo de optimización se usa Adam con tasa 0,001, lotes de 32 y orden sin barajar. A medida que se fue dando el entrenamiento y viendo los resultados, decidimos ampliar el máximo de 100 a 200 épocas y la paciencia de 10 a 20 épocas, ya que veíamos que algunos entrenamientos llegaban hasta la época número 100. Por otra parte, la tasa de aprendizaje se reduce a la mitad después de cinco épocas sin mejora, teniendo como límite inferior 0,00001.

En el entrenamiento se va almacenando la época con menor MSE de validación en la escala transformada. Después del ajuste, se calcula el MAE y RMSE en los casos originales. Las métricas utilizadas son:

- **MAE:** expresa el promedio del error absoluto
- **RMSE:** leda más peso a errores grandes.

El elegido es el menor MAE general en el conjunto de validación, mientras que el RMSE se utiliza en el ranking para resolver empates.

5. Resultados de validación

La tabla a continuación muestra el menor MAE de cada familia de modelos que hemos probado hasta el momento. Cada uno utiliza los mismos 505 objetivos de 2022 a 2023 que consiste en el conjunto de validación.

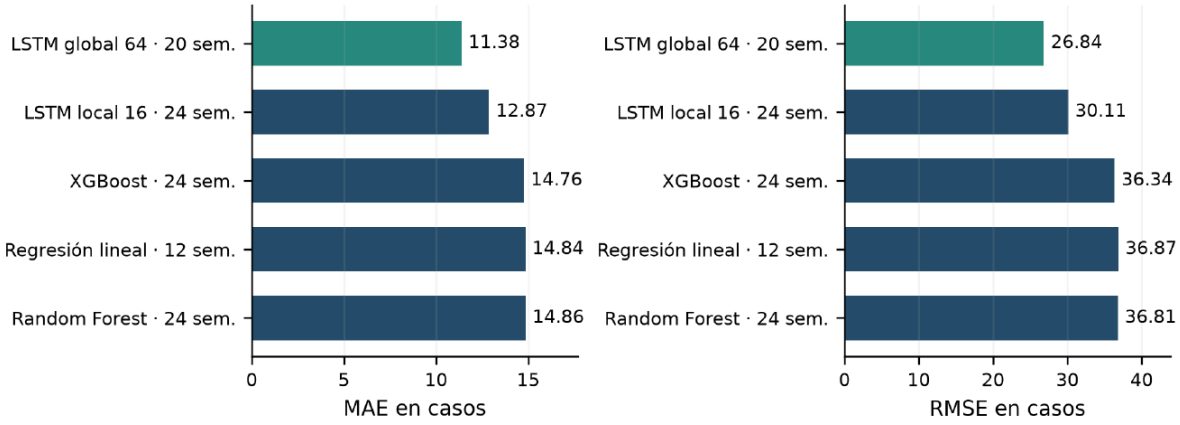


Ilustración 2. Comparación de familias en validación

La LSTM global de 64 unidades adicionando una Dense de 16 neuronas y usando una historia de 20 semanas obtuvo el menor MAE. Este modelo frente al mejor modelo de referencia que fue el XGBoost con una historia de 24 semanas, lo redujo de 14,759 a 11,377 casos, una diferencia aproximada de 23%. Esta es una mejora observada en el bloque de validación. El mejor modelo de los locales fue una red LSTM de 16 unidades adicionando una capa Dense de 8 neuronas con historia de 24 semanas, con MAE de 12,872. La elección que se tiene hasta el momento es el modelo global que ya se mencionó, el cual tiene 19.569 parámetros.

6. Exploración de las seis variantes LSTM con 64 unidades

Dado que en el paso anterior se seleccionó el modelo global usando una LSTM con 64 unidades, decidimos explorar más opciones sobre este modelo. Esta ampliación de modelos incorporó cinco variantes nuevas, además de la que ya se preseleccionó. Lo principal que se varió fue el tamaño de la capa densa intermedia entre 16, 8 y 0 neuronas, también el porcentaje de Dropout que se varió entre 0 y 0.20, y el tamaño de la historia. El resultado se observa a continuación:

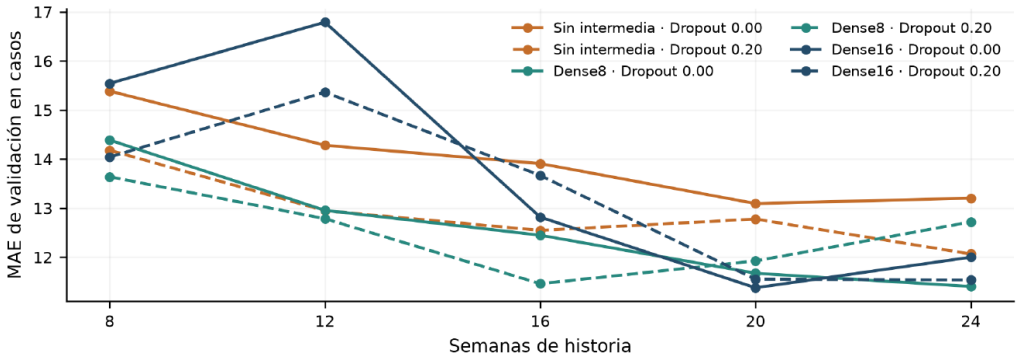


Ilustración 3. MAE por variante e historia

Intermedia	Dropout	Historia	MAE	RMSE
Dense 16	0.0	20	11,377	26,837
Dense 16	0.2	24	11,536	27,867
Dense 8	0.0	24	11,404	26,879
Dense 8	0.2	16	11,459	26,755
Sin intermedia	0.0	20	13,094	32,607
sin intermedia	0.2	24	12,066	28,611

Tabla 2. Menor MAE observado para cada variante LSTM 64

La mejor alternativa entre las exploradas fue la LSTM de 64 unidades con la Dense con 16 neuronas sin Dropout con 20 semanas de historia, el cual tuvo un MAE de 11,377. El modelo de LSTM de 64 unidades con una capa intermedia Dense de 8 neuronas con Dropout de 0,20 y 16 semanas de historia obtuvo MAE 11,459 y el menor RMSE general, que fue de 26,755.

7. Evaluación final y diferencias entre años

A continuación, se realiza la evaluación de los modelos en el conjunto de datos de test, este se caracteriza porque no se ha tocado en todo el desarrollo del proyecto. El periodo del conjunto de datos de test corresponde al periodo de 2024 a 2025. A continuación, se muestra el resultado de los modelos elegidos tanto de referencia como de este proyecto:

Modelo y ventana	MAE	RMSE
Regresión lineal · 12 semanas	31,285	78,708
LSTM global 64 + Dense16 · 20 semanas	38,139	95,413
XGBoost · 24 semanas	40,596	95,975
Random Forest · 24 semanas	43,465	104,825
LSTM local 16 + Dense8 · 24 semanas	48,849	112,727

Tabla 3. Resultados en test de las referencias fijadas con validación

A continuación, se muestra como le fue al modelo elegido, tanto en el conjunto de validación (2022 y 2023) como en el conjunto de test (2024 y 2025):

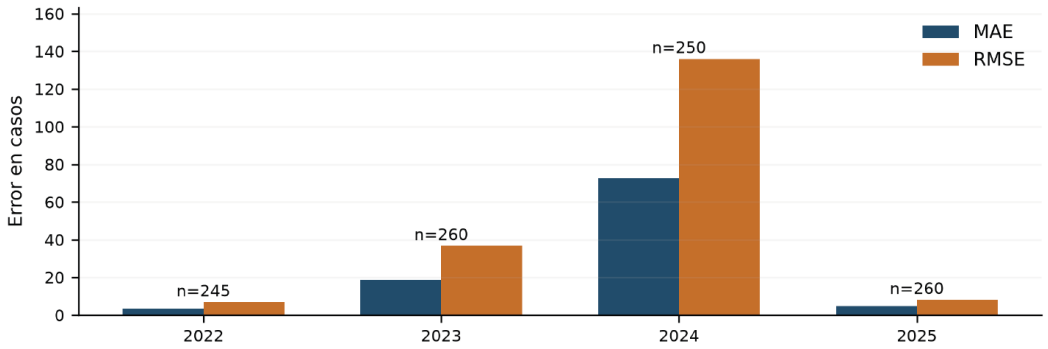


Ilustración 4. Errores anuales del modelo elegido

Vemos en la tabla anterior que la regresión lineal obtuvo el menor MAE y RMSE entre las cinco referencias de test. La LSTM elegida pasó de MAE 11,377 en validación a 38,139 en test. Se puede notar que el error cambia mucho entre años. El MAE de la LSTM fue 3,536 en 2022, 18,766 en 2023, 72,714 en 2024 y 4,894 en 2025.

8. Análisis de los errores

A continuación, se muestra el resultado del modelo seleccionado evaluado en cada municipio independientemente, donde cada uno aporta 101 datos de validación y 102 datos de test.

Municipio	MAE val.	RMSE val.	MAE test	RMSE test
Cali	28,669	41,275	106,906	191,654
Guadalajara de Buga	1,748	2,881	25,625	49,948
Palmira	15,482	38,723	26,161	67,450
Tuluá	2,481	4,129	18,918	36,453
Yumbo	8,505	19,307	13,087	20,342

Tabla 4. Errores municipales del modelo seleccionado

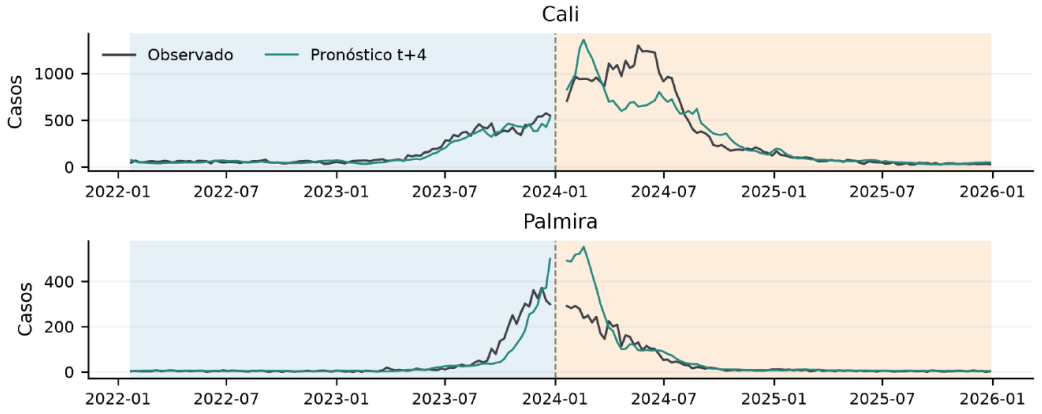


Ilustración 5. Observaciones y pronósticos t+4

Debido a que Cali y Palmira reúnen el mayor número de casos de dengue nos enfocamos en esos dos municipios en la gráfica anterior. En las series de test se observa subestimación durante parte del aumento de Cali y sobreestimación en el comienzo de Palmira.

La tabla mostrada y las gráficas muestran que el modelo pierde precisión al pasar de conjunto de validación a conjunto de test. El aumento del error coincide con las dificultades para anticipar la magnitud y la evolución de los casos durante 2024, ya que fue muy diferente a la historia.

En validación, los errores más altos se presentan en Cali y Palmira, con MAE de 28,669 y 15,482 casos, respectivamente. En test, estos valores aumentan a 106,906 y 26,161 casos. Guadalajara de Buga y Tuluá presentan errores bajos en validación, pero muestran un deterioro considerable en test ya que el MAE pasa de 1,748 a 25,625 casos en Buga y de 2,481 a 18,918 en Tuluá. Yumbo tiene el menor incremento, de 8,505 a 13,087 casos. Estos resultados muestran que el desempeño obtenido en validación no se mantiene de manera uniforme durante el periodo posterior. Sin embargo, los errores absolutos deben interpretarse junto con el volumen de casos de cada municipio.

En Cali, el modelo acompaña visualmente buena parte del crecimiento observado durante 2023. Al comenzar 2024, pronostica un aumento más pronunciado que el registrado y, posteriormente, subestima los valores más altos de la serie. Por tanto, la dificultad no consiste únicamente en anticipar un incremento, sino también en ubicar su momento y estimar su magnitud y duración.

En Palmira, el pronóstico también supera los valores observados al inicio de 2024. La gráfica sugiere que el modelo prolonga el aumento previo y anticipa un pico mayor al que finalmente ocurre. Después, las dos series vuelven a acercarse conforme disminuyen los casos. Durante 2025, las diferencias visuales son menores en ambos municipios.